INSTITUTO UNIVERSITÁRIO DE LISBOA

Análise Exploratória de Dados

Caso Pratico

Guilherme Martins nº139614

Henrique Bombas nº139566

Marius Munteanu nº139581

Santiago Mexia nº139564

Tomas Mourão nº139617

Introdução

O Estudo sobre os Valores Europeus (“European Values Study”) é um programa de investigação em grande escala, transnacional e longitudinal sobre os valores humanos fundamentais. Fornece informações sobre as ideias, crenças, preferências, atitudes, valores e opiniões dos cidadãos de toda a Europa.

O nosso objetivo com este trabalho, é precisamente fazer uma análise detalhada e organizada destes dados, começando pela preparação dos mesmos no próprio Excel, e, de seguida, a análise dos dados descritiva e a sua interpretação em R e estruturação no Jamovi.

Este relatório encontrar-se-á dividido em duas partes, nominadas respetivamente por Fase I – Excel e Fase II – Jamovi, onde, em cada uma delas, explicamos passo a passo os procedimentos que tomamos.

Fase I – Excel

Primeiramente começamos por mudar os nomes das variáveis que existiam inicialmente pela sua correspondência existente na folha de cálculo ***"Variáveis e Códigos"*** para tornar os nomes mais específicos. Por exemplo a variável que ao início tinha o nome de **"v31"** passou a chamar-se **"how much you trust: people your neighborhood".**

Tarefa 1- Aplicar o filtro a todas as variáveis e apresentar a primeira linha fixa

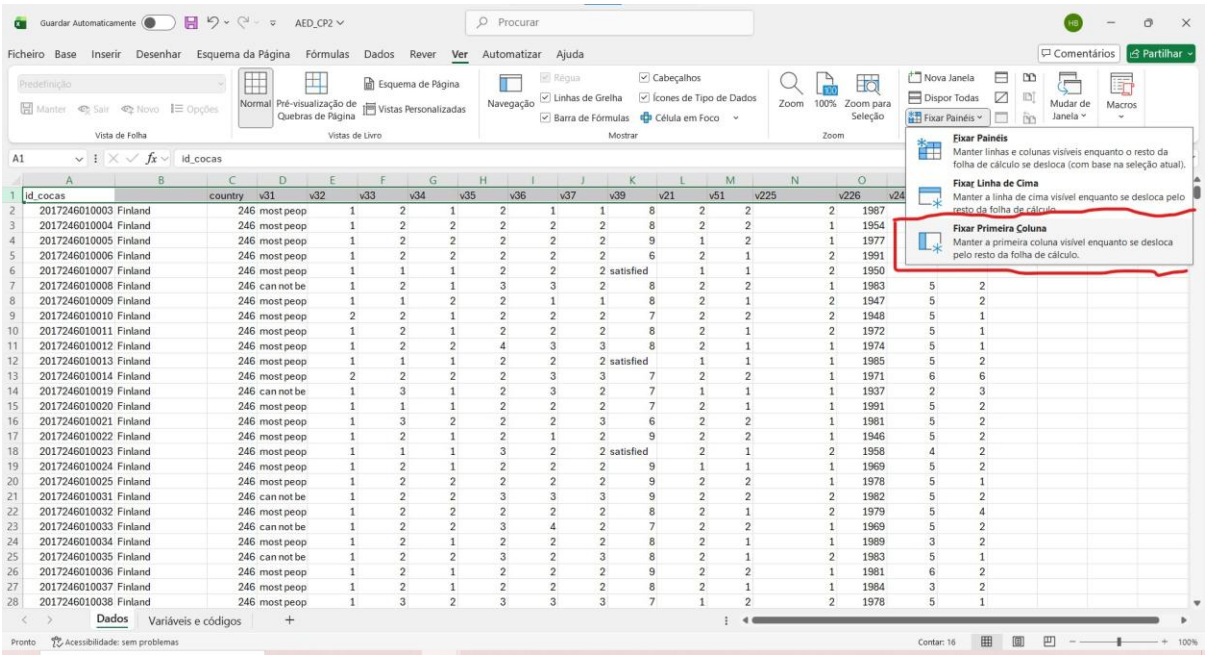


Figura 1 - Fixação da 1ª linha

Começamos por fixar a primeira linha através de *Ver* > *Fixar Painéis* > *Fixar Primeira Linha*. Este método facilita na visualização do Excel para conseguirmos sempre ver os nomes das variáveis, sendo assim mais fácil percebermos que variável estamos a analisar no momento.

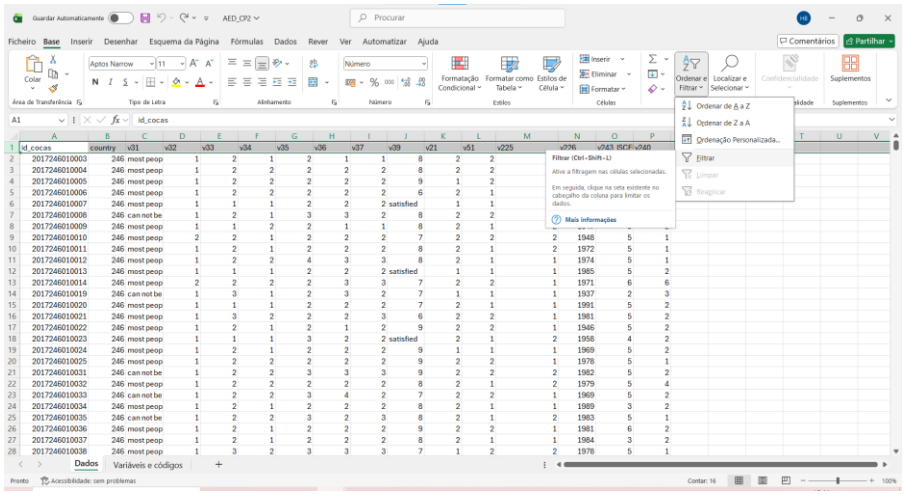


Figura 2- Aplicar o filtro a todas as variáveis

De seguida, também aplicamos um filtro à ***1ª linha das variáveis***. Para isso, selecionamos a *1ª linha - Base* > *Ordenar e Filtrar* > *Filtrar*. Com isto vai aparecer de seguida, uma seta em cada variável que possui as características da mesma, sendo assim mais fácil perceber a existência de valores omissos e erros que as variáveis possam ter.

Tarefa 2 – Atribuir de código de não resposta a uma variável com valores omissos

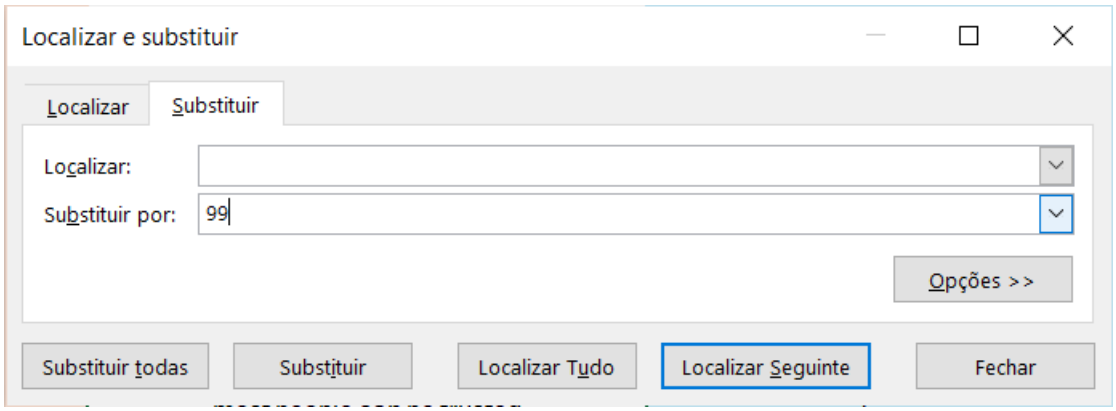


Figura 3 – Atribuir código de não resposta a valores omissos

De modo que não ficassem valores em branco, foi selecionado todo o ficheiro e, utilizando a funcionalidade "**Localizar e substituir**", deixou-se a barra "**Localizar**" em branco (para selecionar os valores em branco, ou seja os valores omissos) e na barra "Substituir por" colocou-se o número 99 (escolhido pelo grupo) para ser mais fácil o uso posterior do ficheiro Excel em R. Este processo foi feito em todo o Excel, logo foi substituído em todas as variáveis.

Tarefa 3 – Atribuir texto às categorias de uma variável que tenha códigos;

De seguida, fizemos a atribuição de texto às categorias de variáveis que tenham códigos. Ao lado de cada variável que tinha código, criámos uma nova coluna com a sua correspondência. Para cada coluna e a sua correspondência atribuímos uma cor aleatória para distinguir mais facilmente cada variável.

Foram feitas atribuições através das fórmulas ***PROCV*** e ***PROCH*** em todas as variáveis exceto nas variáveis "**people can be trusted/can't be too careful**", "**how satisfied are you with your life**", "**year of birth respondent**" e "**number of people in household**", porque estas não possuem nenhuma atribuição. A fórmula transformou valores numéricos em valores nominais numa nova coluna à direita em todas as variáveis exceto nas anteriores.

Em todas as variáveis que foi estabelecida uma correspondência, foi utilizada a função ***PROCV***, exceto nas variáveis "**did you do voluntary work in the last 6 months**", "**do you belong to a religious denomination**" e "**sex respondent**" que foi usada a função ***PROCH***.

Usamos a função ***PROCV*** se a tabela da correspondência dos valores for vertical e usamos a função ***PROCH*** quando a tabela de correspondência da tabela dos valores for horizontal.

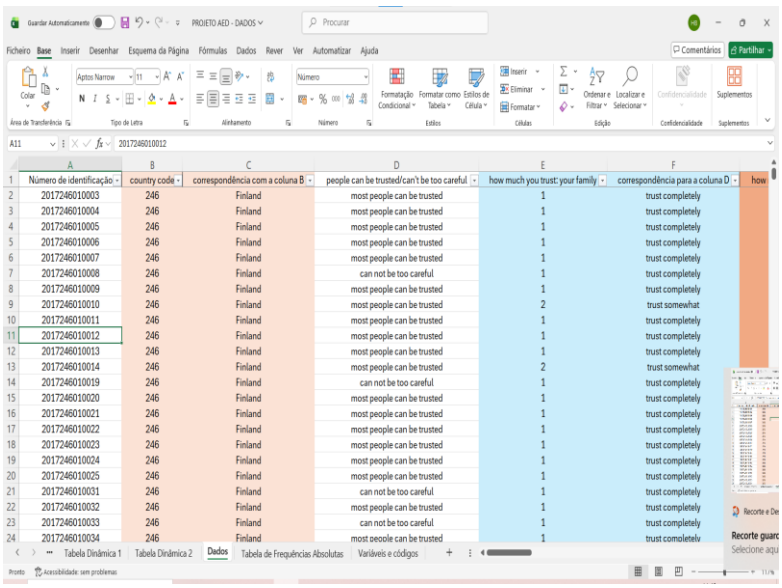
Explicação das funções:

=***PROCV/PROCH*** (célula com o código que se pretende substituir, seleção da tabela de correspondência; nº da coluna da tabela onde deve ser lida a correspondência; FALSE– correspondência exata).

Ou seja, no ***PROCV*** e no ***PROCH*** usamos o mesmo modelo, mas a única diferença é que a tabela onde vai ser lida a correspondência no ***PROCV*** tem de ser vertical e no ***PROCH*** tem de ser horizontal.

Além disso, é preciso ter atenção porque é necessário colocar cifrões nas células da tabela correspondente para que ela não vá buscar outros valores. Fazemos isso através de: *Tecla Fn> F4*

Depois de a fórmula ser aplicada à primeira célula basta só arrastar para as outras.



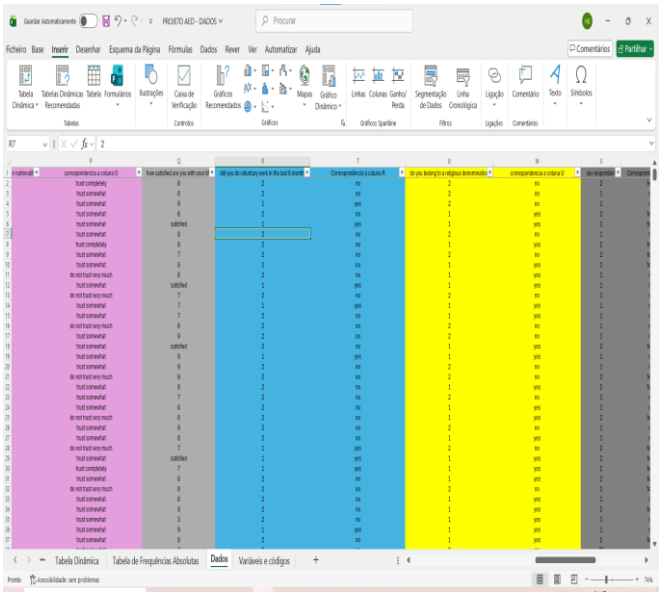


Figura 4 – Uso da função PROCV "country code"

Figura 5 – Uso da função PROCH na variável na variável "did you do voluntary in the last 6 months"

Tarefa 4 – Corrigir possíveis erros

É possível analisar que a variável "**how much you trust: people in your neighborhood**" contém um valor que não está definido, que é o "12".

Acabamos por não substituir este valor porque na nossa análise a pessoa tanto podia querer escrever apenas o número 1 ou apenas o número 2, por isso jogámos pelo seguro e eliminámos a linha toda.

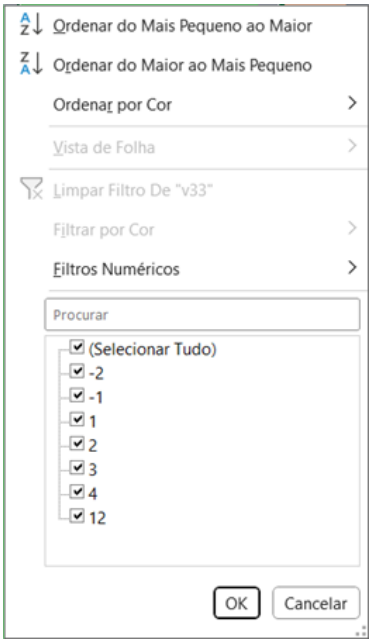


Figura 6 – Filtro da variável "how much you trust: people in your neighborhood"

Também foram encontrados alguns valores numa coluna sem variável que foram eliminados, como é representado na imagem seguinte.

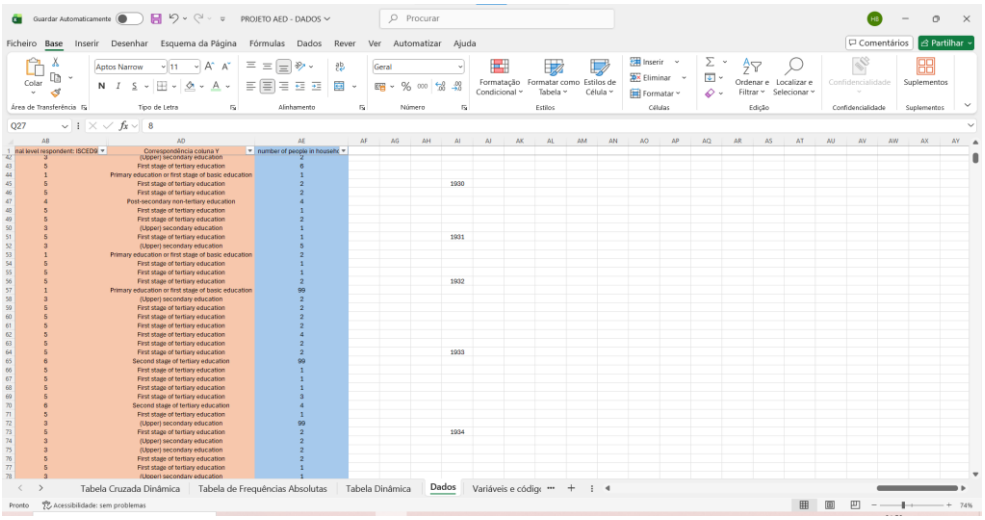


Figura 7 – Valores Aleatórios

A variável “**how satisfeted are with your life**” contém a presença de respostas com valores numéricos e outras com valores nominais simultaneamente, por isso acabamos por não trabalhar muito com essa variável pois não existia uma correspondência possível no nosso ponto de vista. A única coisa que fizemos foi passar um valor de “11” para “10” porque no nosso ponto de vista parecia o mais credível.

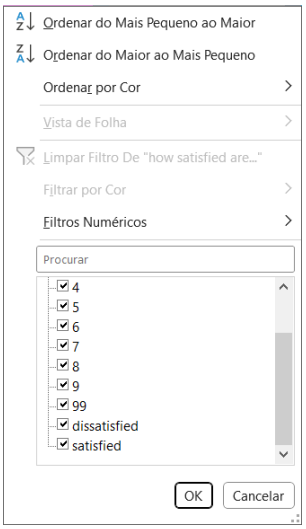


Figura 8 - Filtro da variável “how satisfeted are you with your life”

Tarefa 5 - Criar regras de validação para duas variáveis: uma quantitativa e outra qualitativa

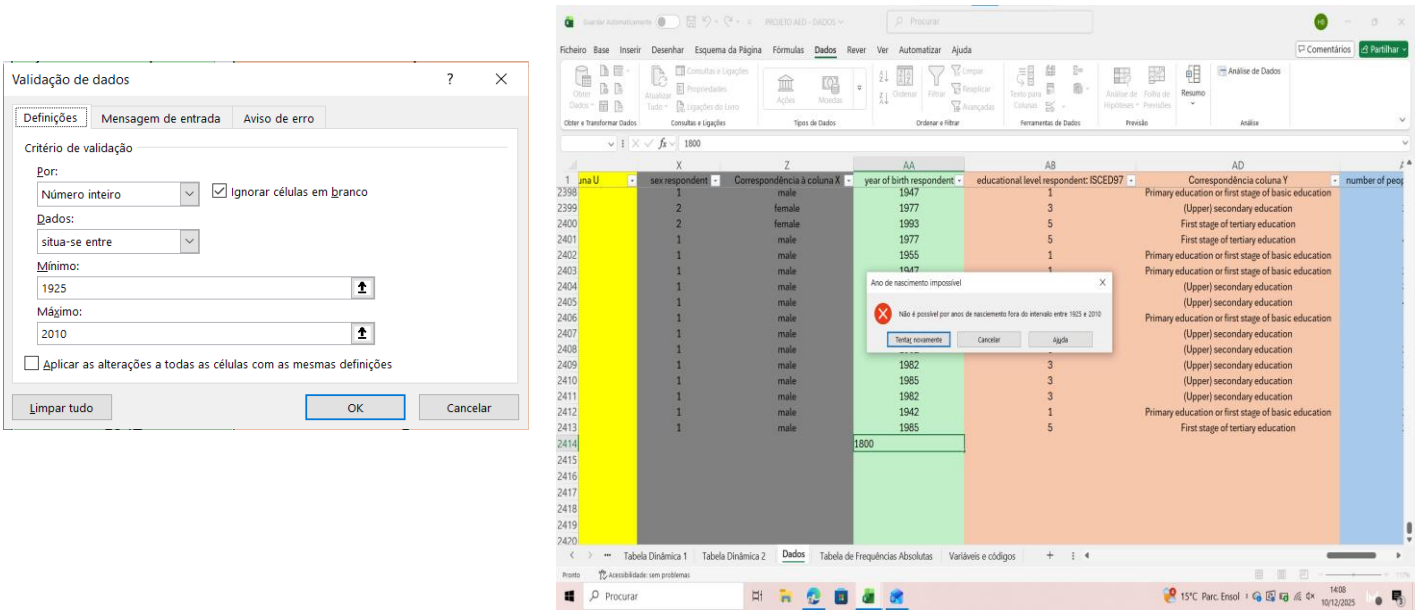
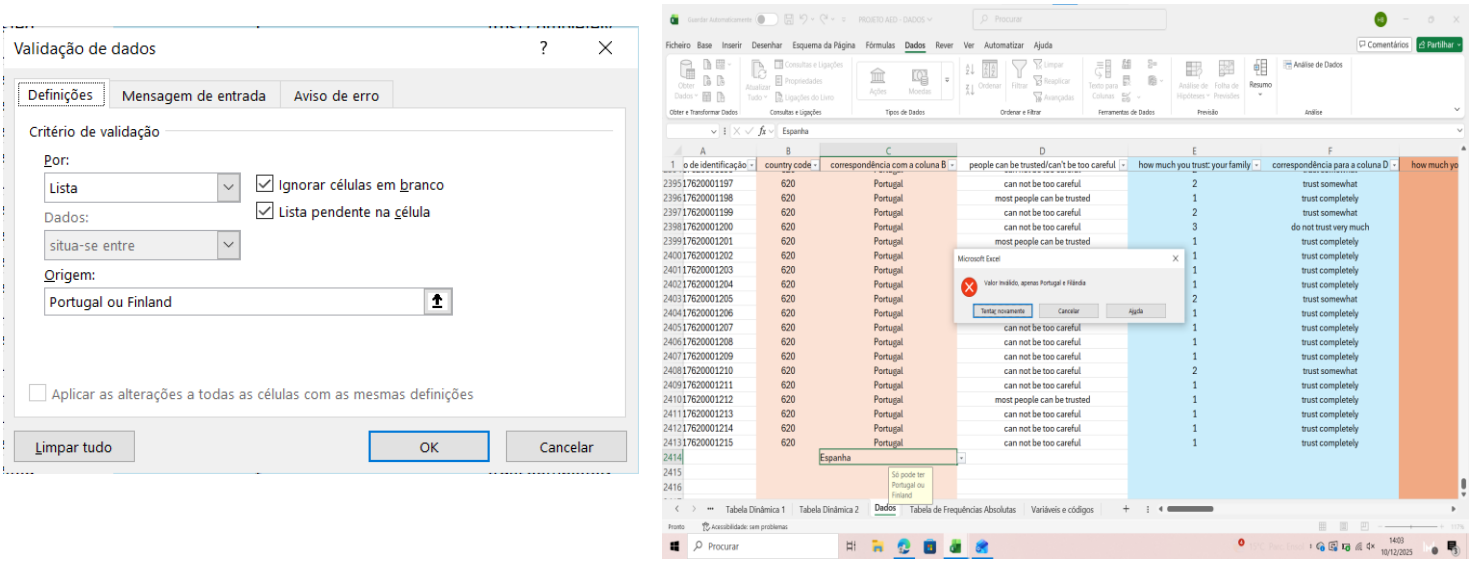


Figura 9 e 10 Validação de variáveis quantitativas

Na regra de validação quantitativa usamos a variável "**year of birth respondent**" que continha valores de **1925** a **2010**, por isso criamos uma regra de validação em que apenas fosse permitido usar um valor compreendido entre esses. Qualquer valor que esteja fora vai originar a mensagem de erro definida. Para criar esta mensagem fomos a **Dados** > **Validação de Dados** e colocamos conforme aparece na mensagem.



Figuras 10 e 11- Validação de variáveis qualitativas

Na variável qualitativa o processo é exatamente o mesmo, mas em vez de ser um intervalo de números inteiros é uma lista. Escolhemos a variável ***country*** e percebemos que apenas vão ser permitidas duas respostas, **Portugal** ou **Finlândia**. Caso se tente colocar qualquer outra coisa vai aparecer a mensagem de erro definida.

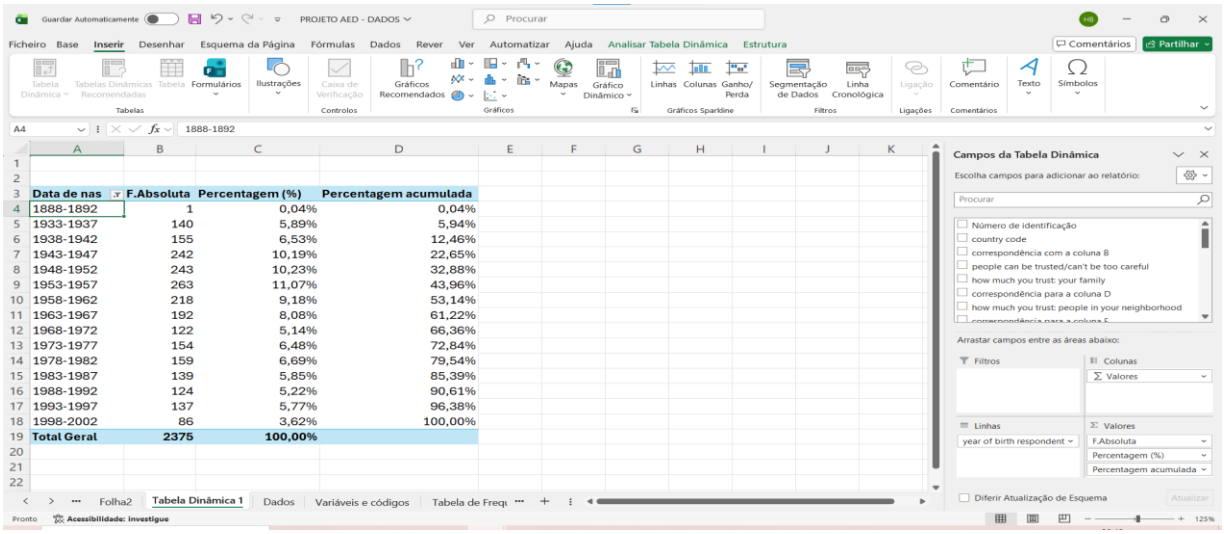
Tarefa 6 – Construir uma tabela de frequências absolutas com funções de contagem e cálculo de percentagens

Sex Respondent	Frequência Absoluta	Percentagem Relativa
Male	1072	44,4813278
Female	1338	55,5186722
Total Geral	2410	100

Figura 12 – Tabela de Frequências Absolutas

Aqui apenas fizemos uma tabela com os valores de frequência absoluta e percentagem. Usamos apenas a fórmula "**CONTAR.SE**" na frequência asboluta para encontrar a quantidade de respostas "**male**" à variável "**sex respondent**" e encontrar a quantidade de respostas "**female**" da mesma variável. Para o total geral fiz a soma das duas células. Na percentagem relativa de "**male**" fizemos a divisão da célula que contém o número de respostas de "**male**" dividimos pelo total geral e multiplicamos por 100. E na percentagem relativa de "female" fizemos a mesma coisa. Para o total geral fizemos a soma das duas variàveis que falei anteriormente.

Tarefa 7 – Construir uma tabela de frequências dinâmica

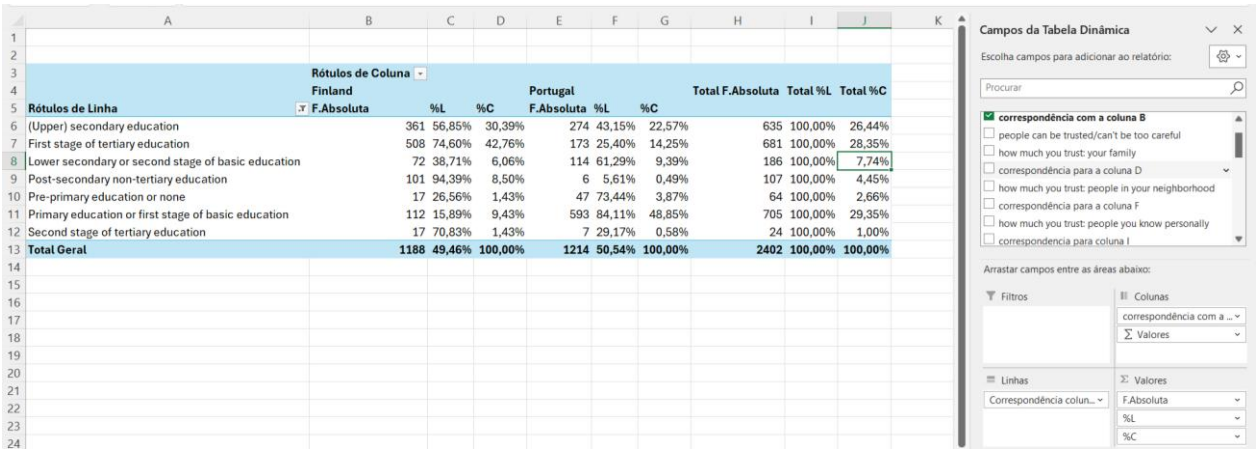


Data de nas	F.Absoluta	Percentagem (%)	Percentagem acumulada
1888-1892	1	0,04%	0,04%
1933-1937	140	5,89%	5,94%
1938-1942	155	6,53%	12,46%
1943-1947	242	10,19%	22,65%
1948-1952	243	10,23%	32,88%
1953-1957	263	11,07%	43,96%
1958-1962	218	9,18%	53,14%
1963-1967	192	8,08%	61,22%
1968-1972	122	5,14%	66,36%
1973-1977	154	6,48%	72,84%
1978-1982	159	6,69%	79,54%
1983-1987	139	5,85%	85,39%
1988-1992	124	5,22%	90,61%
1993-1997	137	5,77%	96,38%
1998-2002	86	3,62%	100,00%
Total Geral	**2375**	**100,00%**	

Figura 13 – Tabela Dinâmica

Para criarmos uma tabela dinâmica, apenas selecionamos todas as linhas e colunas do Excel e fomos a **Inserir** > **Tabela Dinâmica**. A variável escolhida foi a "**year of birth respondent**" e arrastamos para as linhas. Depois arrastamos essa variável **mais 3 vezes** para a caixa dos valores e colocamos valores em frequência absoluta, frequência relativa e frequência relativa acumulada. Todas são usadas com o campo de contagem apesar da Percentagem Relativa ter de mostrar valores como "**% do total geral**" e a percentagem acumulada ter de apresentar valores como "**% do Total Corrente Em**".

Tarefa 8 – Construir uma tabela de cruzamentos dinâmica



	Rótulos de Coluna								
	Finland			Portugal			Total F.Absoluta	Total %L	Total %C
Rótulos de Linha	F.Absoluta	%L	%C	F.Absoluta	%L	%C			
(Upper) secondary education	361	56,85%	30,39%	274	43,15%	22,57%	635	100,00%	26,44%
First stage of tertiary education	508	74,60%	42,76%	173	25,40%	14,25%	681	100,00%	28,35%
Lower secondary or second stage of basic education	72	38,71%	6,06%	114	61,29%	9,39%	186	100,00%	7,74%
Post-secondary non-tertiary education	101	94,39%	8,50%	6	5,61%	0,49%	107	100,00%	4,45%
Pre-primary education or none	17	26,56%	1,43%	47	73,44%	3,87%	64	100,00%	2,66%
Primary education or first stage of basic education	112	15,89%	9,43%	593	84,11%	48,85%	705	100,00%	29,35%
Second stage of tertiary education	17	70,83%	1,43%	7	29,17%	0,58%	24	100,00%	1,00%
Total Geral	**1188**	**49,46%**	**100,00%**	**1214**	**50,54%**	**100,00%**	**2402**	**100,00%**	**100,00%**

Figura 12 – Tabela de cruzamentos dinâmica

Aqui fizemos uma tabela de cruzamentos dinâmica e o processo é todo igual à tabela dinâmica, a única diferença é que esta relaciona 2 variáveis. As variáveis utilizadas foram os países "**Correspondência com a coluna B**" e o **nível de educação** (Correspondência com a coluna Y). Temos representado a frequência absoluta, a percentagem da linha e a percentagem da coluna. A variável do país foi colocada em coluna e a variável do nível de ensino foi colocada em linha.

Fase II – Jamovi

No **Jamovi**, começamos por importar os dados (já limpos e tratados) do Excel, para possibilitar a construção das tabelas e do gráfico.

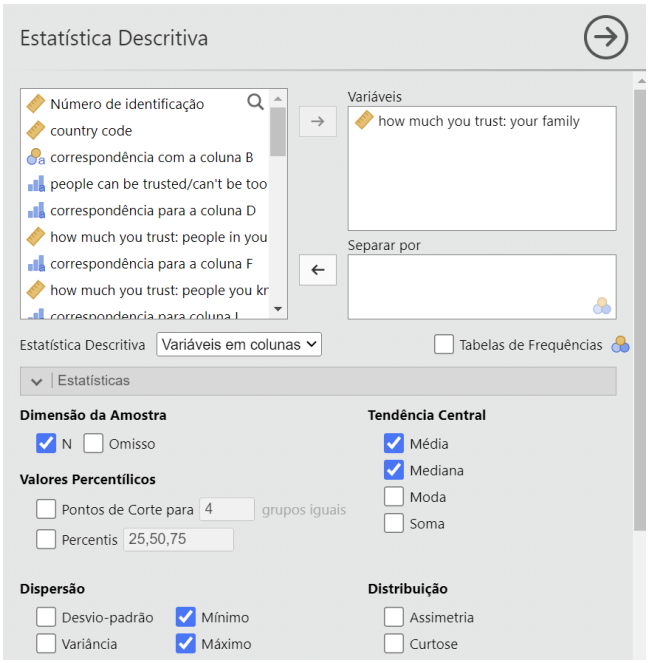
De seguida alteramos os nomes de algumas vareáveis que foram usadas para estudo, de maneira a simplificar a visualização das tabelas/gráfico, como por exemplo a "**correspondência à coluna Y**" para "**education level**"

Outro passo importante foi também a definição dos **valores omissos** (99) para não afetarem o resultado das análises.

Tabela 1:

Ao clicar em **Analises** > **Exploração** é nos possibilitada a entrada na aba da Estatística Descritiva onde procedemos a fazer a construção da tabela 1 com apenas uma variável (how much you trust: your family).

Neste tipo de tabelas optamos por usar as seguintes estatísticas: **N** (número de casos validos), **media**, **mediana**, **mínimo** e **máximo**.



Estatística Descritiva

Estatística Descritiva

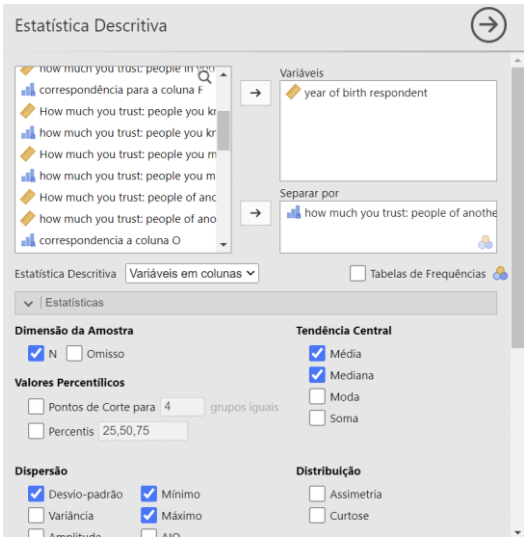
	how much you trust: your family
N	2412
Média	1.22
Mediana	1.00
Mínimo	-2
Máximo	4

É importante saber que as categorias de resposta foram codificadas numericamente para facilitar o cálculo de estatísticas descritivas, conforme segue: trust completely = 1, trust somewhat = 2, ..., do not trust at all = 4, dont know = –1, no answer = –2.

Tabela 2:

A tabela 2 foi feita com duas variáveis. Optamos por escolher: “**year of birth respondent**” e “**how much you trust: people of another religion**”, ficando o primeiro na aba “**variáveis**” (tipo de medida nominal), e o segundo na aba “**separar por**” (tipo de medida contínua).

Nesta tabela acabamos por acrescentar o desvio-padrão às estatísticas.



Estatística Descritiva

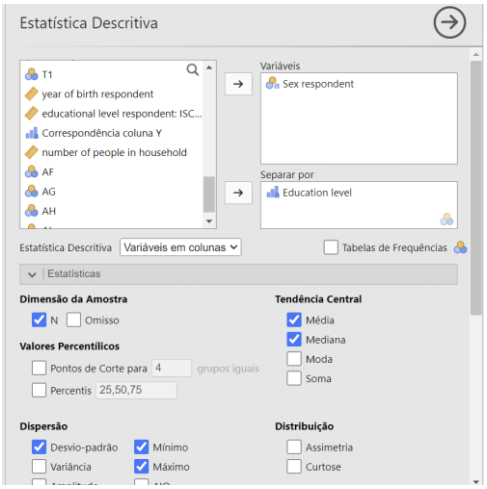
	how much you trust: people of another religion	year of birth respondent
N	do not trust at all	117
	do not trust very much	549
	dont know	88
	no answer	20
	trust completely	276
	trust somewhat	1325
Média	do not trust at all	1963
	do not trust very much	1965
	dont know	1961
	no answer	1967
	trust completely	1959
	trust somewhat	1965
Mediana	do not trust at all	1959
	do not trust very much	1962
	dont know	1957
	no answer	1963
	trust completely	1956
	trust somewhat	1962

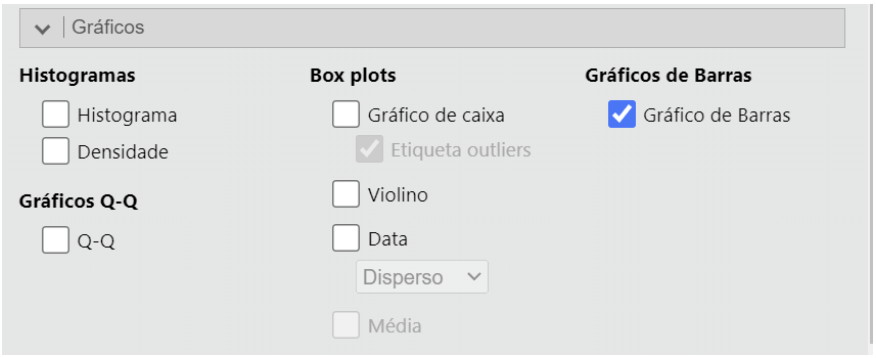
Desvio-padrão	do not trust at all	18.9
	do not trust very much	18.2
	dont know	20.2
	no answer	22.3
	trust completely	17.3
	trust somewhat	18.3
Mínimo	do not trust at all	1937
	do not trust very much	1888
	dont know	1937
	no answer	1937
	trust completely	1937
	trust somewhat	1937
Máximo	do not trust at all	2000
	do not trust very much	2001
	dont know	2002
	no answer	1999
	trust completely	2002
	trust somewhat	2001

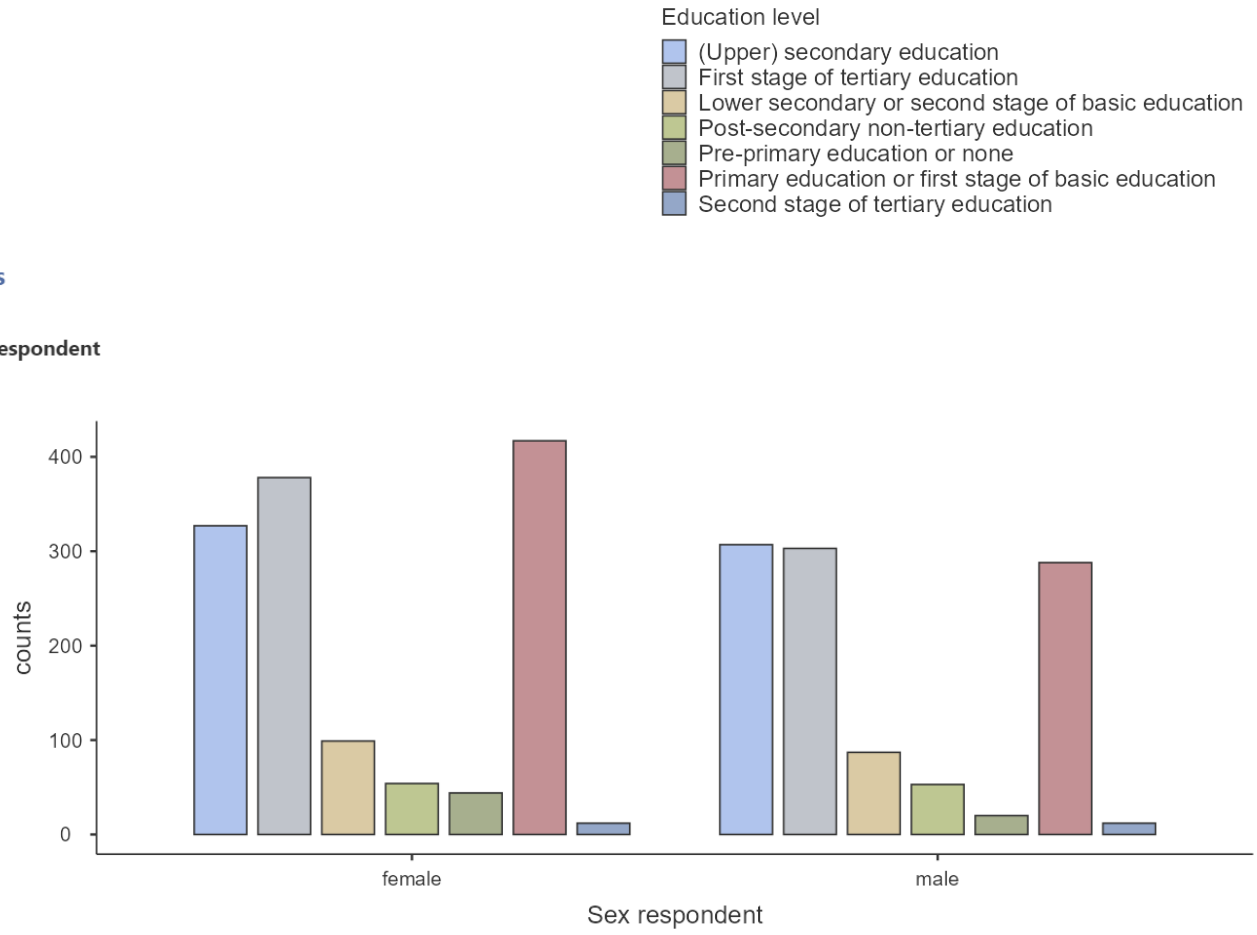
Gráfico:

Para a realização do gráfico seguimos os mesmos passos da tabela anterior, no entanto, trocamos as variáveis, optando por “**sex respondent**” (eixo x) e “**education level**” (eixo y).

Para a criação do gráfico apenas selecionamos a opção “**gráfico de barras**”.






Education level
(Upper) secondary education
First stage of tertiary education
Lower secondary or second stage of basic education
Post-secondary non-tertiary education
Pre-primary education or none
Primary education or first stage of basic education
Second stage of tertiary education
Sex respondent
400
300
200
100
0
counts
female
male
Sex respondent

Gráficos